1. Problema y protocolo

Pronosticar órdenes recibidas por día durante los siguientes 28 días, desde el cierre de cada martes. Alcance: Módulo 0 y Módulo B. La unidad es la orden; la fecha es la compra. El conteo incluye todos los estados finales.

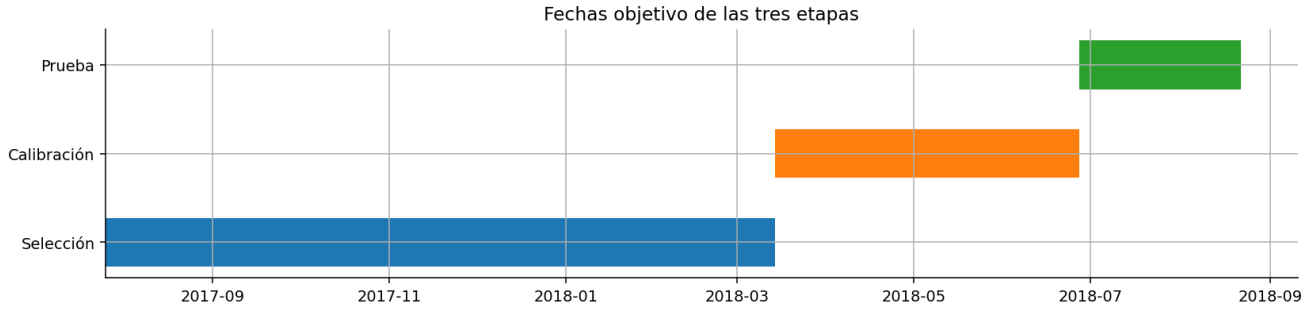
Período útil: 2017-02-01 a 2018-08-21. El corte responde a cobertura y no demuestra una causa específica para la caída de registros al final. Toda la evaluación es retrospectiva: las fechas de prueba ya eran conocidas.

Selección: SARIMAX_calendario, MAE 43.11. Prueba: MAE 65.82, frente a 67.02 de la referencia semanal. La cobertura diaria relativa fue 76.4%, inferior al 90 % nominal.

Los modelos se reajustan en cada emisión. Los objetivos no se cruzan entre etapas; dentro de cada una se solapan las ventanas. No se considera que todos los pares sean independientes.

Fechas objetivo del protocolo

Etapa	Objetivos desde	Objetivos hasta	Emisiones
Selección	2017-07-26	2018-03-13	30
Calibración	2018-03-14	2018-06-26	12
Prueba	2018-06-27	2018-08-21	5



2. Datos, calidad y cobertura

Se consulta DuckDB en modo de solo lectura. SQL realiza lecturas, uniones, filtros, agregaciones y ventanas de datos. La serie nace de orders sin multiplicar compras mediante artículos ni pagos.

El calendario diario completo representa ceros si falta actividad dentro del intervalo. Se obtienen 567 días y 97.590 órdenes; la auditoría concilia sus valores. Las fechas extremas se inspeccionan antes de definir el universo del ejercicio.

EDA común: mediana de entrega 10 días, p90 23 y 6.77% tardías en las observaciones elegibles. Los compradores con varias compras son 2,997 de 96,096 identidades únicas. Los atributos finales de entrega no son predictores.

Calidad relevante al objetivo

Comprobación	Resultado
Órdenes en la base	99441
Filas de unión directa ítems y pagos	118434
Órdenes sin ítems	775
Órdenes sin pagos	1
Diferencias monetarias > 2 centavos	280
Compras sin fecha / IDs duplicados	0 / 0



3. Diagnóstico temporal inicial

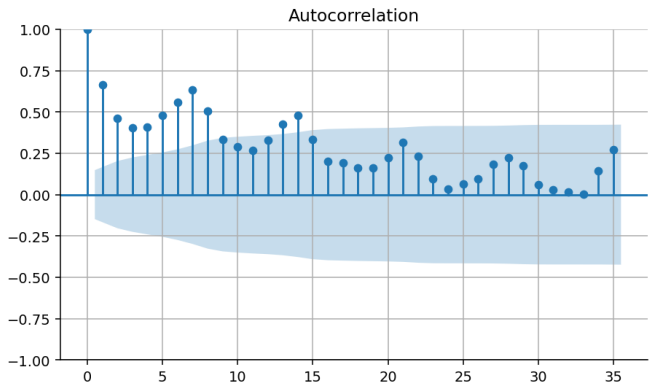
Se estudian solo 175 días, hasta 2017-07-25. Las medias móviles SQL terminan en la fecha observada. El patrón semanal se resume por medias y medianas; no se interpreta causalmente.

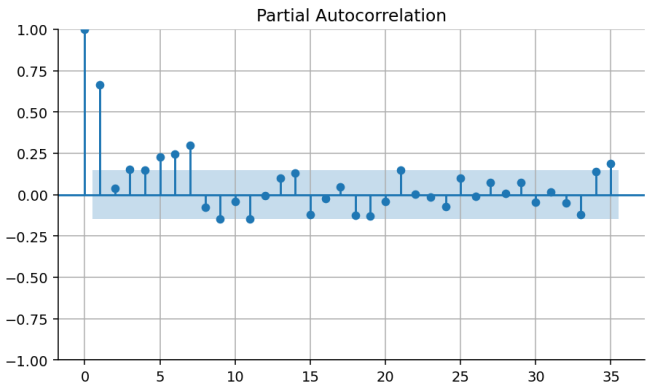
STL robusta con período 7 separa tendencia, semana y residuo para descripción. Sus componentes no se usan como variables porque la descomposición puede utilizar vecinos posteriores dentro del tramo.

ADF y KPSS parten de hipótesis distintas. Nivel: ADF no rechaza raíz unitaria y KPSS rechaza estacionariedad. Diferencia semanal: ADF rechaza y KPSS no rechaza. Las pruebas orientan; no determinan un único modelo.

Pruebas de estacionariedad

serie	ADF_p	KPSS_limite
nivel	0.710938	<= 0.01
diferencia_1	4.71204e-06	0.0417
diferencia_7	0.00176203	>= 0.10





4. Variables y prevención de fuga

Cada ejemplo representa origen o y horizonte h. La historia termina en o, la fecha objetivo es o+h y su calendario sí es conocido. El objetivo real nunca forma parte de las entradas.

Se exige que la fecha de la etiqueta sea menor o igual al origen del ajuste. Filtrar únicamente el origen de la fila permitiría etiquetas todavía desconocidas. Todas las variantes ML comparten filas con 91 días completos de historial.

El modelo ML es directo global: un único modelo aprende todos los horizontes usando h. No utiliza reales intermedios ni una cadena recursiva de predicciones.

Objetivo relativo: log(1+y)-log(1+media28). Inversión: exp(r)*(1+media28)-1, usando la media del origen y recortando a cero. L1 apunta a una mediana condicional; no equivale automáticamente a estimar la media.

Características SQL

Grupo	Contenido
Básicas	Rezagos 0, 6, 13, 27; medias 7/28; dispersión 28
Calendario	Horizonte, semana, mes, tendencia y eventos conocidos
Ampliadas	Últimos 7 días, media 91, razones y dispersión relativa
Día comparable	Último mismo día de semana y media de cuatro
Relativas	Rezagos y días comparables respecto a media 28

Ejemplo desde el primer origen

h	lag_0	media_28	ultimo_mismo_dia	media_4_mismo_dia
1	153	128.39	153	142.75
7	153	128.39	153	158.75
28	153	128.39	153	158.75

5. Candidatos y selección

Ingenuo repite el último valor; Estacional_7 repite la última semana. ETS combina nivel, tendencia amortiguada y semana aditiva. SARIMAX usa log1p, errores ARIMA(1,1,1), seis indicadores semanales y calendario. No tiene diferencia semanal adicional.

Las cuatro variantes LightGBM cruzan variables básicas/ampliadas y objetivo absoluto/relativo con idénticos 300 árboles, 7 hojas y pérdida L1. No se presupone que el relativo sea superior.

Se elige SARIMAX_calendario por MAE en 840 pares. Los días difíciles permanecen. Black Friday 2017 tiene 1.176 pedidos y no había un evento anterior para estimar su magnitud; varios de los mayores errores corresponden a esa fecha.

Los avisos de ajuste se registran; ningún ajuste sin convergencia se acepta. En el primer SARIMAX, Ljung–Box p7=0.0539 y p14=0.2208; no demostrar autocorrelación al 5 % no prueba adecuación universal.

Selección: menor es mejor

modelo	MAE	RMSE	sMAPE
SARIMAX_calendario	43.11	92.22	20.58
LGBM_amplio_absoluto	51.15	102.38	23.59
LGBM_base_absoluto	51.61	103.38	23.67
ETS_amortiguado	53.64	104.96	24.78
Estacional_7	56.64	122.94	25.74
Ingenuo	58.82	101.80	27.86
LGBM_amplio_relativo	64.34	132.02	26.66
LGBM_base_relativo	66.56	139.19	26.90

Factores ML: diferencia negativa favorece al candidato

comparacion	diferencia_MAE	origenes_mejora
Variables con objetivo absoluto	-0.46	13
Variables con objetivo relativo	-2.23	17
Objetivo con variables básicas	14.96	12
Objetivo con variables ampliadas	13.19	13

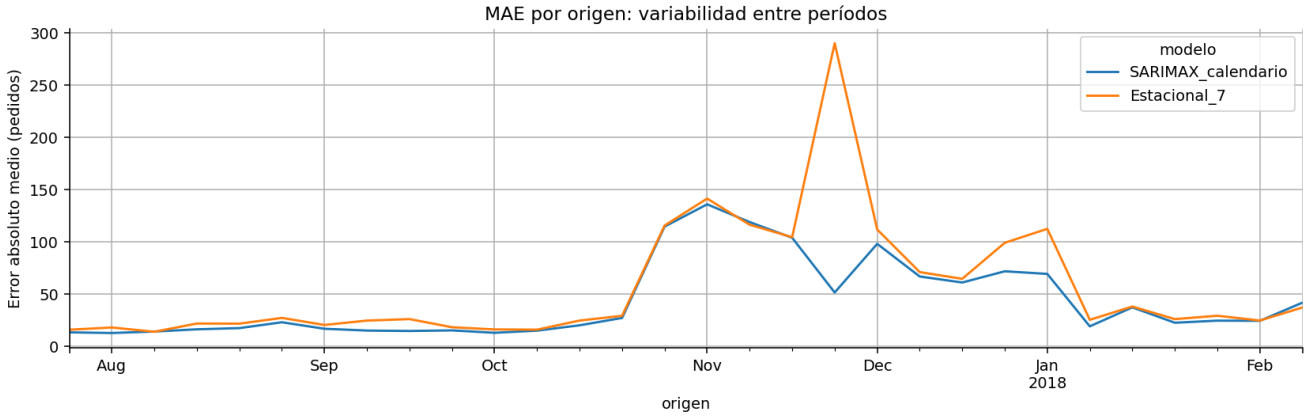
6. Variación entre períodos y errores

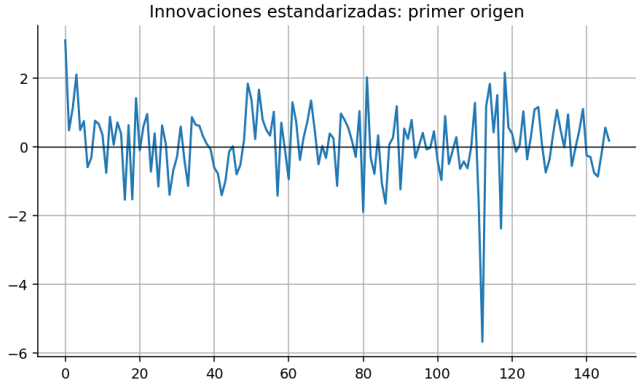
Las diferencias por origen importan: un promedio puede ocultar episodios malos. Las emisiones solapadas no se tratan como observaciones independientes para declarar significancia estadística.

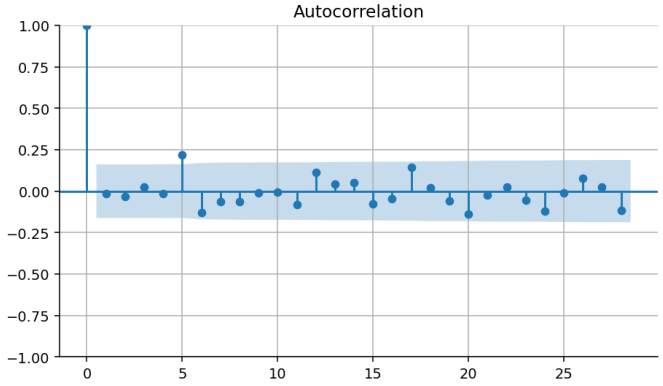
Las variables ampliadas ayudan modestamente al ML absoluto, pero el objetivo relativo empeora el promedio en esta ejecución. Esa conclusión está limitada a candidatos, configuración y protocolo evaluados.

El calendario informa la fecha de un evento, no su magnitud. Se conserva la huelga y no se proporciona un indicador futuro que simule conocimiento previo. Las comparaciones de eventos son descriptivas.

Ljung–Box y la ACF residual examinan estructura remanente. Un ajuste que converge puede seguir teniendo sesgo o errores predictivos importantes.







7. Evaluación retrospectiva

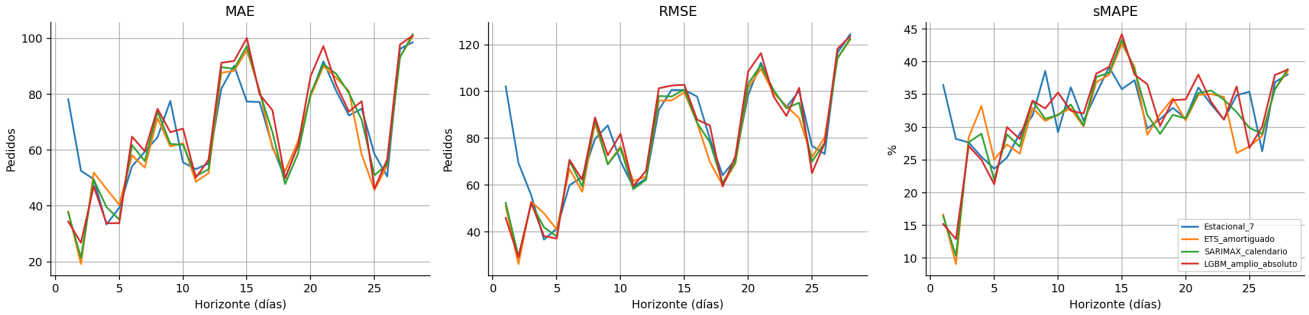
La prueba contiene cinco emisiones, 140 pares por modelo y 56 fechas. Los objetivos centrales se evalúan desde varias anticipaciones. Se exporta también una métrica con igual peso por fecha.

El elegido logra MAE 65.82, una diferencia de 1.79 % frente al estacional. El menor MAE observado pertenece a ETS_amortiguado (65.08); se mantiene la elección de selección.

El sesgo del seleccionado es -43.36 pedidos: subpronóstico promedio. RMSE penaliza picos, sMAPE da una lectura relativa y MAE permanece en pedidos. Los errores por horizonte no tienen por qué crecer de forma monótona.

Prueba: comparación en idénticos pares

modelo	MAE	RMSE	sMAPE
ETS_amortiguado	65.08	80.50	31.01
SARIMAX_calendario	65.82	81.29	31.26
LGBM_base_absoluto	67.01	82.35	31.61
Estacional_7	67.02	84.60	32.40
LGBM_amplio_absoluto	67.32	83.09	31.93
Ingenuo	68.22	84.07	31.49
LGBM_base_relativo	69.31	86.53	33.12
LGBM_amplio_relativo	70.43	86.43	33.43



8. Intervalos y cobertura

La calibración utiliza 12 emisiones reservadas. Por semana del horizonte hay 84 errores diarios y se toma el rango 77 para 90 %. Para cada total semanal hay 12 errores y el rango es 12. Se usa orden estadístico exacto, sin interpolación.

Relativo: |real-pred|/(1+pred); margen q*(1+pred). Absoluto: |real-pred|; margen q. El relativo es principal por diseño y el absoluto es un análisis paralelo. Los cuantiles permanecen fijos en prueba.

Para totales se suman primero reales y puntos y luego se calibra el error del total. No se suman límites diarios. No hay garantía de cobertura conjunta de todos los días o semanas.

El relativo cubre 76.4% diario y 80.0% semanal: no alcanza el 90 % nominal. La dependencia, poca muestra y reajustes impiden atribuir una garantía conformal exacta. Las amplitudes y coberturas deben leerse juntas.

Cobertura diaria (%) y amplitud en pedidos

metodo_intervalo	cubiertos	n	porcentaje	ancho_medio
absoluto	123	140	87.86	230.59
relativo	107	140	76.43	202.46

Cobertura de totales semanales (%)

metodo_intervalo	cubiertos	n	porcentaje	ancho_medio
absoluto	19	20	95.00	1,812.88
relativo	16	20	80.00	1,578.66

9. Pronóstico histórico final

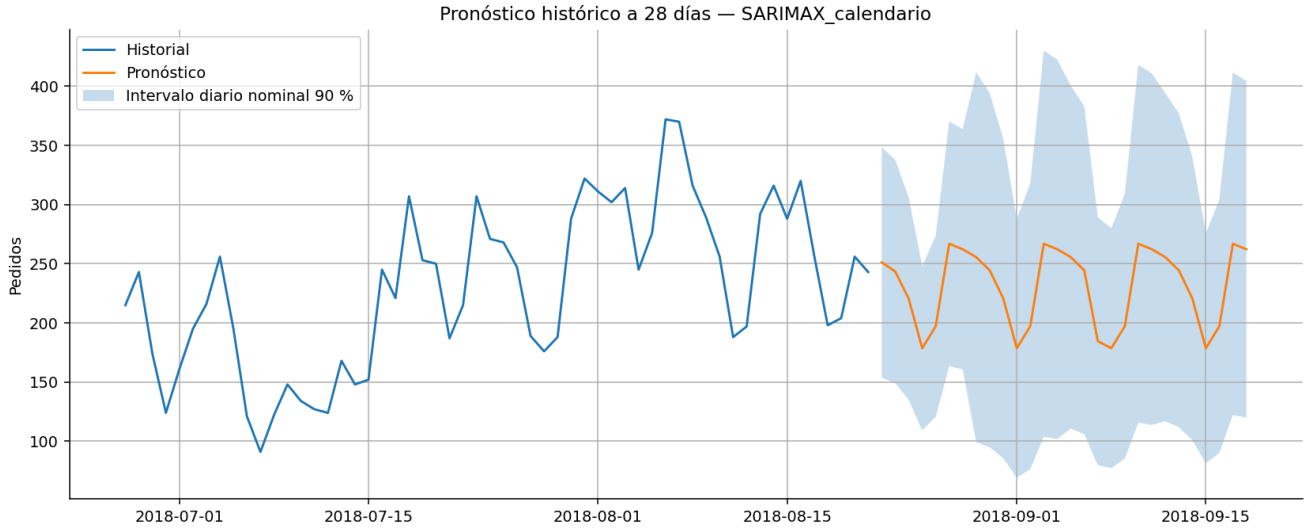
Se reajusta SARIMAX_calendario hasta 2018-08-21 y se pronostica 2018-08-22 a 2018-09-18. Suma de puntos: 6,460.58 pedidos. No es una proyección actual de Olist.

Los CSV conservan precisión decimal. La suma de puntos no se presenta como media esperada ni mediana garantizada del total. Los reales futuros permanecen desconocidos.

Los intervalos finales son los relativos fijados en el protocolo; su cobertura observada fue insuficiente en prueba. No se presentan como márgenes operativamente validados al 90 %. No se anuncia un intervalo mensual sumando los semanales.

Totales semanales con intervalos nominales

semana	desde	hasta	pred	inferior	superior
1	2018-08-22	2018-08-28	1,619.98	972.03	2,267.92
2	2018-08-29	2018-09-04	1,625.55	454.05	2,797.05
3	2018-09-05	2018-09-11	1,589.51	623.55	2,555.47
4	2018-09-12	2018-09-18	1,625.55	614.30	2,636.80



10. Reproducibilidad, auditoría y límites

Entorno: Python 3.12, dependencias directas fijadas en requirements.txt. La base local se construye con el script del curso. El análisis usa SQL y read_only=True; la base no se incluye en la entrega.

Orden: instalar requisitos; construir data/olist.duckdb; ejecutar scripts/ejecutar.py; scripts/auditar.py; scripts/generar_documentacion.py. Los notebooks ya se entregan ejecutados, con figuras incrustadas y comentarios.

La auditoría completa 13 grupos de controles: serie, particiones, métricas independientes, baselines, variables, cuantiles, cobertura y reproducibilidad final. Los ocho modelos reproducen sus pronósticos al retirar físicamente el futuro en dos orígenes.

Límites: período corto, una sola observación útil de Black Friday, dependencia entre emisiones, elección de cobertura temporal y prueba ya examinada. La diferencia de MAE frente al baseline es pequeña y la cobertura principal no alcanza el nivel nominal.

Material didáctico: documentacion/guia_completa.md desarrolla cada concepto y analiza todas las tablas. La importancia por ganancia de ML explica el ajuste sin atribuir causalidad.

Datos: Brazilian E-Commerce Public Dataset by Olist (Kaggle). Revisar licencia CC BY-NC-SA 4.0 antes de redistribuir datos derivados. Referencias metodológicas: Forecasting: Principles and Practice; documentación de statsmodels, LightGBM y holidays.

Controles auditados

Área	Evidencia
SQL y datos	Conteos, regularidad, granularidad y ventanas
Evaluación	Métricas SQL y referencias reproducidas
Fuga	Futuro retirado, 8 modelos, 2 orígenes
Intervalos	Cuantiles y totales conciliados
Notebooks	Tres ejecutados, sin errores y comentados